









Figure 1: The Transformer - model architecture.

- ① 词嵌入编码语义。
- ② 位置 编码 位置信息！上下信息


原词用得到



K V

Attention(Q, k, V)

$$= \text{softmax} \left(\frac{Q k^T}{\sqrt{d_k}} \right) V$$




(每个词之间的相关性)


Q · K 的点积: 得到一个权重, 表示所有 token, 对 token 的语义信息的影响的重要程度

$\text{softmax}(Q \cdot K^T \text{ 得到权重}) \Rightarrow$ 和为 1 的概率

$\Rightarrow$ 权重 1 · 我_V + 权重 2 · 爱_V + 权重 3 · 你_V + 权重 4 · 水_V + 权重 5 · 果_V + 权重 6 · 课_V = 输出 token



的头:



为什么?

512 维的词语
汉字 Vocab
[甜 不甜] head: 口味
[辣 不辣]
[酸 酸]
[量]

为什么线性层?

再做一次映射 $\Rightarrow$ 改变词向量的维度